

约束优化算法

文再文

北京大学北京国际数学研究中心

教材《最优化：建模、算法与理论》配套电子教案

<http://bicmr.pku.edu.cn/~wenzw/optbook.html>

提纲

- 1 二次罚函数法
- 2 等式约束问题的增广拉格朗日函数法
- 3 一般约束问题的增广拉格朗日函数法
- 4 交替方向乘子法

等式约束的二次罚函数法

首先考虑简单情形：仅包含等式约束的约束优化问题

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, \quad i \in \mathcal{E} \end{aligned} \quad (1)$$

其中 $x \in \mathbb{R}^n$, $\mathcal{E}$ 为等式约束的指标集, $c_i(x)$ 为连续函数

定义该问题的二次罚函数为:

$$P_E(x, \sigma) = f(x) + \frac{1}{2}\sigma \sum_{i \in \mathcal{E}} c_i^2(x) \quad (2)$$

其中等式右端第二项称为罚函数, $\sigma > 0$ 称为罚因子

- 由于这种罚函数对不满足约束的点进行惩罚, 在迭代过程中点列一般处于可行域之外, 因此它也被称为外点罚函数.

例1

为了直观理解罚函数的作用，我们给出一个例子：

考虑优化问题

$$\begin{array}{ll}\min & x + \sqrt{3}y \\ \text{s.t.} & x^2 + y^2 = 1\end{array}$$

容易求得最优解为 $\left(-\frac{1}{2}, -\frac{\sqrt{3}}{2}\right)^T$ ，考虑二次罚函数

$$P_E(x, y, \sigma) = x + \sqrt{3}y + \frac{\sigma}{2} (x^2 + y^2 - 1)^2$$

并在下图中绘制出 $\sigma = 1$ 和 $\sigma = 10$ 对应的罚函数的等高线。

例1

取不同的值时二次罚函数 $P_E(x, y, \sigma)$ 的等高线




Figure: (a) $\sigma = 1$




Figure: (b) $\sigma = 10$

例2

下面这个例子表明，当 σ 选取过小时罚函数可能无下界。

考虑优化问题

$$\begin{array}{ll}\min & -x^2 + 2y^2 \\ \text{s.t.} & x = 1\end{array}$$

容易求得最优解为 $(1, 0)^T$ ，然而考虑罚函数

$$P_E(x, y, \sigma) = -x^2 + 2y^2 + \frac{\sigma}{2}(x - 1)^2$$

对任意的 $\sigma \leq 2$ ，该罚函数无下界

二次罚函数法算法

Algorithm 二次罚函数法

- 1: 给定 $\sigma_1 > 0, x_0, k \leftarrow 1$. 罚因子增长系数 $\rho > 1$.
 - 2: **while** 未达到收敛准则 **do**
 - 3: 以 x^k 为初始点, 求解 $x^{k+1} = \arg \min_x P_E(x, \sigma_k)$
 - 4: 选取 $\sigma^{k+1} = \rho \sigma_k$.
 - 5: $k \leftarrow k + 1$
 - 6: **end while**
-

注意事项:

- 选取合适的参数 ρ : σ_k 增长过快会使子问题求解困难, σ_k 增长过慢则会增加迭代次数. 另外, 也可以自适应地调整 ρ
- 检测到迭代点发散就应该立即终止迭代并增大罚因子
- 为保证收敛, 子问题求解误差需要趋于零

分析KKT条件

从KKT条件角度分析：

- 原问题的KKT条件：

$$\begin{aligned}\nabla f(x^*) - \sum_{i \in \mathcal{E}} \lambda_i^* \nabla c_i(x^*) &= 0 \\ c_i(x^*) &= 0, \quad \forall i \in \mathcal{E}\end{aligned}$$

- 添加罚函数项问题的KKT条件：

$$\nabla f(x) + \sum_{i \in \mathcal{E}} \sigma c_i(x) \nabla c_i(x) = 0$$

假设两个问题收敛到同一点，对比KKT条件(梯度式)，应有下式成立：

$$\sigma c_i(x) \approx -\lambda_i^*, \quad \forall i \in \mathcal{E}$$

最优点处乘子 λ^* 固定，为使约束 $c_i(x) = 0$ 成立，需要 $\sigma \rightarrow \infty$

分析数值困难

- 考虑罚函数 $P_E(x, \sigma)$ 的海瑟矩阵:

$$\nabla_{xx}^2 P_E(x, \sigma) = \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \sigma c_i(x) \nabla^2 c_i(x) + \sigma \nabla c(x) \nabla c(x)^T$$

- 等号右边的前两项可以使用拉格朗日函数 $L(x, \lambda^*)$ 来近似, 即:

$$\nabla_{xx}^2 P_E(x, \sigma) \approx \nabla_{xx}^2 L(x, \lambda^*) + \sigma \nabla c(x) \nabla c(x)^T$$

- 右边为一个定值矩阵和一个最大特征值趋于正无穷的矩阵, 这导致 $\nabla_{xx}^2 P_E(x, \sigma)$ 条件数越来越大, 求解子问题的难度也会相应地增加.
- 此时使用梯度类算法求解将会变得非常困难. 若使用牛顿法, 则求解牛顿方程本身就是一个非常困难的问题. 因此在实际应用中, 我们不可能令罚因子趋于正无穷.

一般约束问题的二次罚函数法

考虑不等式约束问题：

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & c_i(x) \leq 0, i \in \mathcal{I}\end{array}$$

定义该问题的二次罚函数为：

$$P_I(x, \sigma) = f(x) + \frac{1}{2}\sigma \sum_{i \in \mathcal{I}} \tilde{c}_i^2(x)$$

其中 $\tilde{c}_i(x)$ 定义为：

$$\tilde{c}_i(x) = \max \{c_i(x), 0\}$$

注： $h(t) = (\min\{t, 0\})^2$ 关于 t 可导，故 $P_I(x, \sigma)$ 梯度存在，所以可以使用梯度类算法求解，或者考虑能处理不可微情形的二阶算法，如半光滑牛顿法等等。

一般约束问题的二次罚函数法

现在考虑一般约束问题：

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & c_i(x) = 0, i \in \mathcal{E} \\ & c_i(x) \leq 0, i \in \mathcal{I}\end{array}$$

定义该问题的二次罚函数为：

$$P(x, \sigma) = f(x) + \frac{1}{2}\sigma \left[\sum_{i \in \mathcal{E}} c_i^2(x) + \sum_{i \in \mathcal{I}} \tilde{c}_i^2(x) \right]$$

其中等式右端第二项称为惩罚项， $\tilde{c}_i(x)$ 的定义如(3)式，常数 $\sigma > 0$ 称为罚因子。

提纲

- 1 二次罚函数法
- 2 等式约束问题的增广拉格朗日函数法
- 3 一般约束问题的增广拉格朗日函数法
- 4 交替方向乘子法

二次罚函数法的数值困难

对于等式约束问题:

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, \quad i \in \mathcal{E} \end{aligned} \tag{3}$$

二次罚函数法需要求解最小化罚函数的子问题:

$$\min_x \quad P_E(x, \sigma) = f(x) + \frac{1}{2}\sigma \sum_{i \in \mathcal{E}} c_i^2(x).$$

由 $c_i(x^{k+1}) \approx -\frac{\lambda_i^*}{\sigma_k}$, 为了满足可行性条件, 必须使 σ_k 趋于 ∞ , 这造成了子问题求解的数值困难.

我们接下来介绍的增广拉格朗日函数法可以利用有限的罚因子逼近最优解, 从而避免了上述必须使罚因子迅速膨胀的数值困难.

等式约束问题的增广拉格朗日函数法

增广拉格朗日函数法的每步都需要构造增广拉格朗日函数. 根据不同的约束, 增广拉格朗日函数的形式也不同, 因此我们分别论述.

定义

等式约束问题的增广拉格朗日函数

对于等式约束问题(3), 定义增广拉格朗日函数为:

$$L_{\sigma}(x, \lambda) = f(x) + \sum_{i \in \mathcal{E}} \lambda_i c_i(x) + \frac{1}{2} \sigma \sum_{i \in \mathcal{E}} c_i^2(x).$$

这即是在拉格朗日函数的基础上添加等式约束的二次罚函数.

由定义可得, 在第 k 步迭代, 给定罚因子 σ_k 和乘子 λ^k , $L_{\sigma_k}(x, \lambda^k)$ 的最小值点 x^{k+1} 应满足梯度条件

$$\nabla_x L_{\sigma_k}(x^{k+1}, \lambda^k) = \nabla f(x^{k+1}) + \sum_{i \in \mathcal{E}} (\lambda_i^k + \sigma_k c_i(x^{k+1})) \nabla c_i(x^{k+1}) = 0.$$

(4)

等式约束问题的增广拉格朗日函数法

我们将(4)式对比优化问题(3)满足的KKT条件(对最优解 (x^*, λ^*) 的梯度条件)

$$\nabla f(x^*) + \sum_{i \in \mathcal{E}} \lambda_i^* \nabla c_i(x^*) = 0, \quad (5)$$

为保证(4)和(5)式在最优解处的一致性, 对充分大的 k , 应满足:

$$\lambda_i^* \approx \lambda_i^k + \sigma_k c_i(x^{k+1}), \quad \forall i \in \mathcal{E}, \quad (6)$$

即等价于

$$c_i(x^{k+1}) \approx \frac{1}{\sigma_k} (\lambda_i^* - \lambda_i^k).$$

由此得出我们希望设计的增广拉格朗日算法具有如下的特性.

性质

- 增广拉格朗日函数法通过合理更新乘子, 即通过控制 $\lambda_i^* - \lambda_i^k$ 降低约束违反度.
因为根据约束违反度满足的公式, 当 λ_i^k 足够接近 λ_i^* 时, $c_i(x^{k+1})$ 将远小于 $1/\sigma_k$.
- (6) 式的一个截断近似可以写为:

$$\lambda_i^{k+1} = \lambda_i^k + \sigma_k c_i(x^{k+1}), \quad \forall i \in \mathcal{E},$$

这可以作为算法中乘子的更新方式.

根据如上讨论, 并对 $c(x)$, $\nabla c(x)$ 沿用罚函数法的定义, 我们将在下文写出等式约束问题增广拉格朗日函数法的具体算法.

等式约束问题的增广拉格朗日函数法

Algorithm 增广拉格朗日函数法

Require: 初始坐标 $x^0 \in \mathbb{R}^n$, 乘子 λ^0 , 罚因子 $\sigma_0 > 0$, 约束违反度常数 $\varepsilon > 0$, 精度 $\eta_k > 0$, 迭代步 $k = 0$.

Ensure: x^{k+1}, λ^k .

- 1: 检查初始元素.
 - 2: **for** $k = 0, 1, 2, \dots$ **do do**
 - 3: 以 x^k 为初始点, 求解 $\min_x L_{\sigma_k}(x, \lambda^k)$, 得到满足需求的精度条件 $\|\nabla_x L_{\sigma_k}(x, \lambda^k)\| \leq \eta_k$ 的解 x^{k+1} .
 - 4: **if** $\|c(x^{k+1})\| \leq \varepsilon$ **then**
 - 5: 返回近似解 (x^{k+1}, λ_k) , 终止迭代.
 - 6: **end if**
 - 7: 更新乘子: $\lambda^{k+1} = \lambda^k + \sigma_k c(x^{k+1})$.
 - 8: 更新罚因子: $\sigma_{k+1} = \rho \sigma_k$.
 - 9: **end for**
-

使用增广拉格朗日函数法的实例

我们考虑优化问题

$$\begin{array}{ll}\min & x + \sqrt{3}y, \\ \text{s.t.} & x^2 + y^2 = 1.\end{array}$$

容易求得最优解为 $x^* = \left(-\frac{1}{2}, -\frac{\sqrt{3}}{2}\right)^T$, 相应的拉格朗日乘子 $\lambda^* = 1$.

根据增广拉格朗日函数的形式, 写出本问题的增广拉格朗日函数:

$$L_{\sigma}(x, y, \lambda) = x + \sqrt{3}y + \lambda (x^2 + y^2 - 1) + \frac{\sigma}{2} (x^2 + y^2 - 1)^2,$$

并在下图中绘制 $L_2(x, y, 0.9)$ 的等高线.

二次罚函数法与增广拉格朗日函数法求解的等高线

图中标“*”的点为原问题的最优解 x^*

标“o”的点为罚函数或增广拉格朗日函数的最优解




Figure: (a) 二次罚函数




Figure: (b) 增广拉格朗日函数

比较与结论

我们比较二次罚函数和增广拉格朗日函数在最优解探寻方面的有效性.

- 二次罚函数法求出的最优解为 $(-0.5957, -1.0319)$, 与最优解的欧氏距离约0.1915, 约束违反度为0.4197.
- 增广拉格朗日罚函数法求出的最优解为 $(-0.5100, -0.8833)$, 与最优解的欧氏距离约0.02, 约束违反度为0.0403.

由此可见, 成立如下的经验性结论.

性质

增广拉格朗日函数法可具有比二次罚函数法更精确的寻优能力, 且约束违反度一般更低.

ρ 与 σ_k 的取值指导

在每次迭代确定 σ_k 时, 应考虑如下的问题.

- σ_k 不应增长过快:

(1) 随着罚因子 σ_k 的增大, 可见 $L_{\sigma_k}(x, \lambda^k)$ 关于 x 的海瑟矩阵的条件数也将增大, 这将导致数值困难;

(2) σ_k 与 σ_{k+1} 接近时, x^k 可以作为求解 x^{k+1} 的初始点, 以加快收敛.

- σ_k 不应增长过慢: 算法整体的收敛速度将变慢(惩罚不足).
-

因此在实际中, 我们应该控制 σ_k 的增长维持在一个合理的速度区间内. 一个简单的方法是维持 $\rho \in [2, 10]$, 不过近年来也有学者设计了更合理的自适应方法.

提纲

- 1 二次罚函数法
- 2 等式约束问题的增广拉格朗日函数法
- 3 一般约束问题的增广拉格朗日函数法
- 4 交替方向乘子法

一般约束问题的增广拉格朗日函数法

一般的约束优化问题可以写成

$$\begin{aligned} \min \quad & f(x), \\ \text{s.t.} \quad & c_i(x) = 0, i \in \mathcal{E}, \\ & c_i(x) \leq 0, i \in \mathcal{I}. \end{aligned} \tag{7}$$

对于问题(7), 我们一般引入松弛变量, 得到如下等价形式:

$$\begin{aligned} \min_{x,s} \quad & f(x), \\ \text{s.t.} \quad & c_i(x) = 0, i \in \mathcal{E}, \\ & c_i(x) + s_i = 0, i \in \mathcal{I}, \\ & s_i \geq 0, i \in \mathcal{I}. \end{aligned} \tag{8}$$

这样的做法我们已经用过多次了, 读者应熟练掌握.

构造增广拉格朗日函数

保留非负约束, 可以构造拉格朗日函数

$$L(x, s, \lambda, \mu) = f(x) + \sum_{i \in \mathcal{E}} \lambda_i c_i(x) + \sum_{i \in \mathcal{I}} \mu_i (c_i(x) + s_i), s_i \geq 0, i \in \mathcal{I}.$$

记问题(8)中等式约束的二次罚函数为 $p(x, s)$, 即

$$p(x, s) = \sum_{i \in \mathcal{E}} c_i^2(x) + \sum_{i \in \mathcal{I}} (c_i(x) + s_i)^2,$$

那么可以同样构造增广拉格朗日函数如下:

$$L_\sigma(x, s, \lambda, \mu) = f(x) + \sum_{i \in \mathcal{E}} \lambda_i c_i(x) + \sum_{i \in \mathcal{I}} \mu_i (c_i(x) + s_i) + \frac{\sigma}{2} p(x, s), \quad s_i \geq 0, i \in \mathcal{I}.$$

消元法求解子问题

在第 k 步迭代中, 给定乘子 λ^k, μ^k 和罚因子 σ_k , 需要求解如下问题:

$$\min_{x,s} L_{\sigma_k}(x, s, \lambda^k, \mu^k), \quad \text{s.t.} \quad s \geq 0, \quad (9)$$

以得到 x^{k+1}, s^{k+1} .

我们现在介绍一种基于消元的方法, 即考虑消去 s , 求解只关于 x 的优化问题.

- 首先固定 x , 关于 s 的子问题化为

$$\min_{s \geq 0} \sum_{i \in \mathcal{I}} \mu_i (c_i(x) + s_i) + \frac{\sigma_k}{2} \sum_{i \in \mathcal{I}} (c_i(x) + s_i)^2.$$

容易直接解得使子问题最优且满足非负约束的 s_i 为

$$s_i = \max \left\{ -\frac{\mu_i}{\sigma_k} - c_i(x), 0 \right\}, \quad i \in \mathcal{I}. \quad (10)$$

消元法求解子问题

- 将 s_i 的表达式代入 L_{σ_k} 我们有

$$L_{\sigma_k}(x, \lambda^k, \mu^k) = f(x) + \sum_{i \in \mathcal{E}} \lambda_i c_i(x) + \frac{\sigma_k}{2} \sum_{i \in \mathcal{E}} c_i^2(x) + \frac{\sigma_k}{2} \sum_{i \in \mathcal{I}} \left(\max \left\{ \frac{\mu_i}{\sigma_k} + c_i(x), 0 \right\}^2 - \frac{\mu_i^2}{\sigma_k^2} \right).$$

其为关于 x 的连续可微函数(假设 $f(x), c_i(x), i \in \mathcal{I} \cup \mathcal{E}$ 连续可微). 因此, 问题(9)等价于

$$\min_{x \in \mathbb{R}^n} L_{\sigma_k}(x, \lambda^k, \mu^k).$$

并且可以利用梯度法进行求解.

注意: 这里, 我们消去了变量 s , 因此可以只考虑关于 x 的优化问题.

更新乘子

对于问题(8), 其最优解 x^*, s^* 和乘子 λ^*, μ^* 需满足KKT 条件:

$$\begin{aligned} 0 &= \nabla f(x^*) + \sum_{i \in \mathcal{E}} \lambda_i^* \nabla c_i(x^*) + \sum_{i \in \mathcal{I}} \mu_i^* \nabla c_i(x^*), \\ \mu_i^* &\geq 0, \quad s_i^* \geq 0, \quad i \in \mathcal{I} \end{aligned}$$

问题(9)的最优解 x^{k+1}, s^{k+1} 满足

$$\begin{aligned} 0 &= \nabla f(x^{k+1}) + \sum_{i \in \mathcal{E}} (\lambda_i^k + \sigma_k c_i(x^{k+1})) \nabla c_i(x^{k+1}) + \\ &\quad \sum_{i \in \mathcal{I}} (\mu_i^k + \sigma_k (c_i(x^{k+1}) + s_i^{k+1})) \nabla c_i(x^{k+1}), \\ s_i^{k+1} &= \max \left\{ -\frac{\mu_i^k}{\sigma_k} - c_i(x^{k+1}), 0 \right\}, \quad i \in \mathcal{I}. \end{aligned}$$

对比问题(8)和问题(9)的KKT 条件, 易知乘子的更新格式为

$$\begin{aligned} \lambda_i^{k+1} &= \lambda_i^k + \sigma_k c_i(x^{k+1}), \quad i \in \mathcal{E}, \\ \mu_i^{k+1} &= \max \{ \mu_i^k + \sigma_k c_i(x^{k+1}), 0 \}, \quad i \in \mathcal{I}. \end{aligned} \tag{11}$$

提纲

- 1 二次罚函数法
- 2 等式约束问题的增广拉格朗日函数法
- 3 一般约束问题的增广拉格朗日函数法
- 4 交替方向乘子法

典型问题形式

考虑如下凸问题：

$$\begin{aligned} \min_{x_1, x_2} \quad & f_1(x_1) + f_2(x_2), \\ \text{s.t.} \quad & A_1 x_1 + A_2 x_2 = b, \end{aligned} \tag{12}$$

- f_1, f_2 是适当的闭凸函数，但不要求是光滑的， $x_1 \in \mathbb{R}^n, x_2 \in \mathbb{R}^m$, $A_1 \in \mathbb{R}^{p \times n}, A_2 \in \mathbb{R}^{p \times m}, b \in \mathbb{R}^p$.
- 问题特点：目标函数可以分成彼此分离的两块，但是变量被线性约束结合在一起。常见的一些无约束和带约束的优化问题都可以表示成这一形式。

增广拉格朗日函数法

- 首先写出问题(12)的增广拉格朗日函数

$$\begin{aligned} L_{\rho}(x_1, x_2, y) = & f_1(x_1) + f_2(x_2) + y^T(A_1x_1 + A_2x_2 - b) \\ & + \frac{\rho}{2}\|A_1x_1 + A_2x_2 - b\|_2^2, \end{aligned} \quad (13)$$

其中 $\rho > 0$ 是二次罚项的系数.

- 常见的求解带约束问题的增广拉格朗日函数法为如下更新:

$$(x_1^{k+1}, x_2^{k+1}) = \underset{x_1, x_2}{\operatorname{argmin}} L_{\rho}(x_1, x_2, y^k), \quad (14)$$

$$y^{k+1} = y^k + \tau \rho (A_1 x_1^{k+1} + A_2 x_2^{k+1} - b), \quad (15)$$

其中 τ 为步长.

交替方向乘子法

Alternating direction method of multipliers, ADMM

- 交替方向乘子法的基本思路: 第一步迭代(14)同时对 x_1 和 x_2 进行优化有时候比较困难, 而固定一个变量求解关于另一个变量的极小问题可能比较简单, 因此我们可以考虑对 x_1 和 x_2 交替求极小
- 其迭代格式可以总结如下:

$$x_1^{k+1} = \underset{x_1}{\operatorname{argmin}} L_\rho(x_1, x_2^k, y^k), \quad (16)$$

$$x_2^{k+1} = \underset{x_2}{\operatorname{argmin}} L_\rho(x_1^{k+1}, x_2, y^k), \quad (17)$$

$$y^{k+1} = y^k + \tau \rho(A_1 x_1^{k+1} + A_2 x_2^{k+1} - b), \quad (18)$$

其中 τ 为步长, 通常取值于 $\left(0, \frac{1+\sqrt{5}}{2}\right]$

原问题最优性条件

- 因为 f_1, f_2 均为闭凸函数，约束为线性约束，所以当Slater条件成立时，可以使用凸优化问题的KKT条件来作为交替方向乘子法的收敛准则。问题(12)的拉格朗日函数为

$$L(x_1, x_2, y) = f_1(x_1) + f_2(x_2) + y^T(A_1x_1 + A_2x_2 - b).$$

- 根据最优性条件定理，若 x_1^*, x_2^* 为问题(12)的最优解， y^* 为对应的拉格朗日乘子，则以下条件满足：

$$0 \in \partial_{x_1} L(x_1^*, x_2^*, y^*) = \partial f_1(x_1^*) + A_1^T y^*, \quad (19a)$$

$$0 \in \partial_{x_2} L(x_1^*, x_2^*, y^*) = \partial f_2(x_2^*) + A_2^T y^*, \quad (19b)$$

$$A_1 x_1^* + A_2 x_2^* = b. \quad (19c)$$

在这里条件(19c)又称为原始可行性条件，条件(19a)和条件(19b)又称为对偶可行性条件。

ADMM单步迭代最优性条件

- 由 x_2 的更新步骤

$$x_2^k = \operatorname{argmin}_x \left\{ f_2(x) + \frac{\rho}{2} \left\| A_1 x_1^k + A_2 x - b + \frac{y^{k-1}}{\rho} \right\|^2 \right\},$$

根据最优性条件不难推出

$$0 \in \partial f_2(x_2^k) + A_2^T [y^{k-1} + \rho(A_1 x_1^k + A_2 x_2^k - b)]. \quad (20)$$

当 $\tau = 1$ 时, 根据(18)可知上式方括号中的表达式就是 y^k , 最终有

$$0 \in \partial f_2(x_2^k) + A_2^T y^k,$$

- 由 x_1 的更新公式

$$x_1^k = \operatorname{argmin}_x \left\{ f_1(x) + \frac{\rho}{2} \|A_1 x + A_2 x_2^{k-1} - b + \frac{y^{k-1}}{\rho}\|^2 \right\},$$

假设子问题能精确求解, 根据最优性条件

$$0 \in \partial f_1(x_1^k) + A_1^T [\rho(A_1 x_1^k + A_2 x_2^{k-1} - b) + y^{k-1}].$$

ADMM单步迭代最优性条件

- 根据ADMM的第三式(18)取 $\tau = 1$ 有

$$0 \in \partial f_1(x_1^k) + A_1^T(y^k + \rho A_2(x_2^{k-1} - x_2^k)). \quad (21)$$

对比条件(19a)可知多出来的项为 $A_1^T A_2(x_2^{k-1} - x_2^k)$ 。因此要检测对偶可行性只需要检测残差

$$s^k = A_1^T A_2(x_2^{k-1} - x_2^k)$$

- 综上当 x_2 更新取到精确解且 $\tau = 1$ 时，判断ADMM是否收敛只需要检测前述两个残差 r^k, s^k 是否充分小：

$$\begin{aligned} 0 &\approx \|r^k\| = \|A_1 x_1^k + A_2 x_2^k - b\| && \text{(原始可行性)}, \\ 0 &\approx \|s^k\| = \|A_1^T A_2(x_2^{k-1} - x_2^k)\| && \text{(对偶可行性)}. \end{aligned} \quad (22)$$

LASSO 问题的Primal 形式

- LASSO 问题

$$\min \quad \mu \|x\|_1 + \frac{1}{2} \|Ax - b\|^2.$$

转换为标准问题形式：

$$\begin{aligned} \min_{x,z} \quad & \frac{1}{2} \|Ax - b\|^2 + \mu \|z\|_1, \\ \text{s.t.} \quad & x = z. \end{aligned}$$

- 交替方向乘子法迭代格式为

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_x \left\{ \frac{1}{2} \|Ax - b\|^2 + \frac{\rho}{2} \|x - z^k + y^k/\rho\|^2 \right\}, \\ &= (A^T A + \rho I)^{-1} (A^T b + \rho z^k - y^k), \\ z^{k+1} &= \operatorname{argmin}_z \left\{ \mu \|z\|_1 + \frac{\rho}{2} \|x^{k+1} - z + y^k/\rho\|^2 \right\}, \\ &= \operatorname{prox}_{(\mu/\rho)\|\cdot\|_1} (x^{k+1} + y^k/\rho), \\ y^{k+1} &= y^k + \tau \rho (x^{k+1} - z^{k+1}). \end{aligned}$$

LASSO 问题的Primal 形式

- 注意，因为 $\rho > 0$ ，所以 $A^T A + \rho I$ 总是可逆的。 x 迭代本质上是计算一个岭回归问题（ ℓ_2 范数平方正则化的最小二乘问题）；而对 z 的更新为 ℓ_1 范数的邻近算子，同样有显式解。在求解 x 迭代时，若使用固定的罚因子 ρ ，我们可以缓存矩阵 $A^T A + \rho I$ 的初始分解，从而减小后续迭代中的计算量。
- 需要注意的是，在 LASSO 问题中，矩阵 $A \in \mathbb{R}^{m \times n}$ 通常有较多的列（即 $m \ll n$ ），因此 $A^T A \in \mathbb{R}^{n \times n}$ 是一个低秩矩阵，二次罚项的作用就是将 $A^T A$ 增加了一个正定项。该 ADMM 主要运算量来自更新 x 变量时求解线性方程组，复杂度为 $O(n^3)$
- 如果 A 低秩，可以利用 SMW 公式计算

$$(A^T A + \rho I)^{-1} = \rho^{-1} I - \rho^{-1} A^T (\rho I + A A^T)^{-1} A$$

LASSO 问题的对偶形式

- 考虑LASSO 问题的对偶问题

$$\begin{aligned} \min \quad & b^T y + \frac{1}{2} \|y\|^2, \\ \text{s.t.} \quad & \|A^T y\|_\infty \leq \mu. \end{aligned} \quad (23)$$

- 引入约束 $A^T y + z = 0$, 可以得到如下等价问题:

$$\begin{aligned} \min \quad & \underbrace{b^T y + \frac{1}{2} \|y\|^2}_{f(y)} + \underbrace{I_{\|z\|_\infty \leq \mu}(z)}_{h(z)}, \\ \text{s.t.} \quad & A^T y + z = 0. \end{aligned} \quad (24)$$

- 对约束 $A^T y + z = 0$ 引入乘子 x , 对偶问题的增广拉格朗日函数为

$$L_\rho(y, z, x) = b^T y + \frac{1}{2} \|y\|^2 + I_{\|z\|_\infty \leq \mu}(z) - x^T (A^T y + z) + \frac{\rho}{2} \|A^T y + z\|^2.$$

LASSO 问题的对偶形式

- 当固定 y, x 时, 对 z 的更新即向无穷范数球 $\{z \mid \|z\|_\infty \leq \mu\}$ 做欧几里得投影, 即将每个分量截断在区间 $[-\mu, \mu]$ 中; 当固定 z, x 时, 对 y 的更新即求解线性方程组

$$(I + \rho AA^T)y = A(x^k - \rho z^{k+1}) - b.$$

- 因此得到ADMM 迭代格式为

$$\begin{aligned} z^{k+1} &= \mathcal{P}_{\|z\|_\infty \leq \mu} (x^k / \rho - A^T y^k), \\ y^{k+1} &= (I + \rho AA^T)^{-1} (A(x^k - \rho z^{k+1}) - b), \\ x^{k+1} &= x^k - \tau \rho (A^T y^{k+1} + z^{k+1}). \end{aligned}$$

- 虽然ADMM 应用于对偶问题也需要求解一个线性方程组, 但由于LASSO 问题的特殊性 ($m \ll n$), 求解 y 更新的线性方程组需要的计算量是 $O(m^3)$, 使用缓存分解技巧后可进一步降低至 $O(m^2)$, 这大大小于针对原始问题的ADMM.

广义LASSO 问题

- 对许多问题 x 本身不稀疏，但在某种变换下是稀疏的：

$$\min_x \mu \|Fx\|_1 + \frac{1}{2} \|Ax - b\|^2. \quad (25)$$

- 一个重要的例子是当 $F \in \mathbb{R}^{(n-1) \times n}$ 是一阶差分矩阵

$$F_{ij} = \begin{cases} 1, & j = i + 1, \\ -1, & j = i, \\ 0, & \text{其他}, \end{cases}$$

且 $A = I$ 时，广义LASSO问题为

$$\min_x \frac{1}{2} \|x - b\|^2 + \mu \sum_{i=1}^{n-1} |x_{i+1} - x_i|,$$

这个问题就是图像去噪问题的TV模型；当 $A = I$ 且 F 是二阶差分矩阵时，问题(25)被称为一范数趋势滤波。

广义LASSO 问题

- 通过引入约束 $Fx = z$:

$$\begin{aligned} \min_{x,z} \quad & \frac{1}{2} \|Ax - b\|^2 + \mu \|z\|_1, \\ \text{s.t.} \quad & Fx - z = 0, \end{aligned} \tag{26}$$

- 引入乘子 y , 其增广拉格朗日函数为

$$L_\rho(x, z, y) = \frac{1}{2} \|Ax - b\|^2 + \mu \|z\|_1 + y^T (Fx - z) + \frac{\rho}{2} \|Fx - z\|^2.$$

- 此问题的 x 迭代是求解方程组

$$(A^T A + \rho F^T F)x = A^T b + \rho F^T \left(z^k - \frac{y^k}{\rho} \right),$$

而 z 迭代依然通过 ℓ_1 范数的邻近算子.

广义LASSO 问题

- 因此交替方向乘法所产生的迭代为

$$x^{k+1} = (A^T A + \rho F^T F)^{-1} \left(A^T b + \rho F^T \left(z^k - \frac{y^k}{\rho} \right) \right),$$

$$z^{k+1} = \text{prox}_{(\mu/\rho)\|\cdot\|_1} \left(Fx^{k+1} + \frac{y^k}{\rho} \right),$$

$$y^{k+1} = y^k + \tau \rho (Fx^{k+1} - z^{k+1}).$$

- 对于全变差去噪问题, $A^T A + \rho F^T F$ 是三对角矩阵, 所以此时 x 迭代可以在 $\mathcal{O}(n)$ 的时间复杂度内解决; 对于图像去模糊问题, A 是卷积算子, 则利用傅里叶变换可将求解方程组的复杂度降低至 $\mathcal{O}(n \log n)$; 对于一范数趋势滤波问题, $A^T A + \rho F^T F$ 是五对角矩阵, 所以 x 迭代仍可以在 $\mathcal{O}(n)$ 的时间复杂度内解决

矩阵分离问题

- 考虑矩阵分离问题：

$$\begin{aligned} \min_{X, S} \quad & \|X\|_* + \mu \|S\|_1, \\ \text{s.t.} \quad & X + S = M, \end{aligned} \tag{27}$$

其中 $\|\cdot\|_1$ 与 $\|\cdot\|_*$ 分别表示矩阵 ℓ_1 范数与核范数。

- 引入乘子 Y 作用在约束 $X + S = M$ 上，我们可以得到此问题的增广拉格朗日函数

$$L_\rho(X, S, Y) = \|X\|_* + \mu \|S\|_1 + \langle Y, X + S - M \rangle + \frac{\rho}{2} \|X + S - M\|_F^2. \tag{28}$$

矩阵分离问题

- 对于 X 子问题,

$$\begin{aligned} X^{k+1} &= \operatorname{argmin}_X L_\rho(X, S^k, Y^k) \\ &= \operatorname{argmin}_X \left\{ \|X\|_* + \frac{\rho}{2} \left\| X + S^k - M + \frac{Y^k}{\rho} \right\|_F^2 \right\}, \\ &= \operatorname{argmin}_X \left\{ \frac{1}{\rho} \|X\|_* + \frac{1}{2} \left\| X + S^k - M + \frac{Y^k}{\rho} \right\|_F^2 \right\}, \\ &= U \operatorname{Diag} \left(\operatorname{prox}_{(1/\rho)\|\cdot\|_1}(\sigma(A)) \right) V^T, \end{aligned}$$

其中 $A = M - S^k - \frac{Y^k}{\rho}$, $\sigma(A)$ 为 A 的所有非零奇异值构成的向量并且 $U \operatorname{Diag}(\sigma(A)) V^T$ 为 A 的约化奇异值分解.

矩阵分离问题

- 对于 S 子问题,

$$\begin{aligned} S^{k+1} &= \operatorname{argmin}_S L_\rho(X^{k+1}, S, Y^k) \\ &= \operatorname{argmin}_S \left\{ \mu \|S\|_1 + \frac{\rho}{2} \left\| X^{k+1} + S - M + \frac{Y^k}{\rho} \right\|_F^2 \right\} \\ &= \operatorname{prox}_{(\mu/\rho)\|\cdot\|_1} \left(M - X^{k+1} - \frac{Y^k}{\rho} \right). \end{aligned}$$

- 那么交替方向乘子法的迭代格式为

$$\begin{aligned} X^{k+1} &= U \operatorname{Diag} \left(\operatorname{prox}_{(1/\rho)\|\cdot\|_1} (\sigma(A)) \right) V^T, \\ S^{k+1} &= \operatorname{prox}_{(\mu/\rho)\|\cdot\|_1} \left(M - L^{k+1} - \frac{Y^k}{\rho} \right), \\ Y^{k+1} &= Y^k + \tau \rho (X^{k+1} + S^{k+1} - M). \end{aligned}$$

图像去噪模型

$$b = Kx_t + w$$

- x_t 为未知图像
- b 为观察到的图像，模糊且有噪声； w 为噪声
- $N \times N$ 的像素点按列储存为长为 N^2 的向量

模糊矩阵 K

- 表示一个2维的卷积，是有空间不动点的扩散函数
- 满足周期边界条件，有循环块(circulant blocks)
- 可对角化，即存在酉的2维离散傅立叶变换矩阵 W ，使得

$$K = W^H \mathbf{diag}(\lambda) W.$$

系数矩阵为 $I + K^T K$ 的线性方程组可在 $O(N^2 \log N)$ 的时间内求解。

全变差去模糊方法

$$\begin{aligned} \min \quad & \|Kx - b\|_1 + \gamma \|Dx\|_{tv} \\ \text{s.t.} \quad & 0 \leq x \leq 1 \end{aligned}$$

目标函数的第二项称为全变差罚函数

- Dx 是离散化的水平和垂直的方向导数

$$\begin{pmatrix} I \otimes D_1 \\ D_1 \otimes I \end{pmatrix}, \quad \begin{pmatrix} -1 & 0 & 0 & \cdots & 0 & 0 & 1 \\ 1 & -1 & 0 & \cdots & 0 & 0 & 0 \\ 0 & 1 & -1 & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & -1 & 0 & 0 \\ 0 & 0 & 0 & \cdots & 1 & -1 & 0 \\ 0 & 0 & 0 & \cdots & 0 & 1 & -1 \end{pmatrix}$$

- $\|\cdot\|_{tv}$ 是欧式距离的和: $\|(u, v)\|_{tv} = \sum_{i=1}^n \sqrt{u_i^2 + v_i^2}$

ADMM求解图像去模糊问题

考虑对原问题进行拆分:

$$\min \|u\|_1 + \gamma \|v\|_{tv}, \quad \text{s.t. } u = Kx - b, \quad v = Dx, \quad y = x, \quad 0 \leq y \leq 1$$

ADMM 算法要求:

- 将 $\|u\|_1$ 和 $\|v\|_{tv}$ 的proximal算子以及在集合 C 上的投影这三部分分离
- 在 $O(N^2 \log N)$ 的时间内求解系数矩阵为 $I + K^T K + D^T D$ 的线性方程组

图像去模糊的实例

- 1024×1024 的图像，满足周期边界条件
- 高斯模糊
- 椒盐噪声 (salt-and-pepper noise) : 50% 的像素点被随机替换为0/1



original



noisy/blurred



restored

非凸约束问题

考虑如下约束优化问题：

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}), \\ \text{s.t.} \quad & \mathbf{x} \in \mathcal{S}, \end{aligned}$$

其中 f 是凸的，但是 $\mathcal{S}$ 是非凸的。可以将上述问题改写为：

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) + \mathbb{I}_{\mathcal{S}}(\mathbf{z}), \\ \text{s.t.} \quad & \mathbf{x} - \mathbf{z} = \mathbf{0}, \end{aligned}$$

交替方向乘子法产生如下迭代：

$$\begin{aligned} \mathbf{x}^{k+1} &= \operatorname{argmin}_{\mathbf{x}} \left(f(\mathbf{x}) + (\rho/2) \|\mathbf{x} - \mathbf{z}^k + \mathbf{u}^k\|_2^2 \right), \\ \mathbf{z}^{k+1} &= \Pi_{\mathcal{S}}(\mathbf{x}^{k+1} + \mathbf{u}^k), \\ \mathbf{u}^{k+1} &= \mathbf{u}^k + (\mathbf{x}^{k+1} - \mathbf{z}^{k+1}) \end{aligned}$$

其中， $\Pi_{\mathcal{S}}(\mathbf{z})$ 是将 $\mathbf{z}$ 投影到集合 $\mathcal{S}$ 中。因为 f 是凸的，所以上述 $\mathbf{x}$ -极小化步是凸问题，但是 $\mathbf{z}$ -极小化步是向一个非凸集合的投影。

非凸约束问题

一般来说，这种投影很难计算，但是在下面列出的这些特殊情形中可以精确求解。

- 基数：如果 $\mathcal{S} = \{\mathbf{x} | \text{card}(\mathbf{x}) \leq c\}$ ，其中 $\text{card}(\mathbf{v})$ 表示非零元素的数目，那么 $\Pi_{\mathcal{S}}(\mathbf{v})$ 保持前 c 大的元素不变，其他元素变为 0。

例如回归选择（也叫特征选择）问题：

$$\begin{aligned} \min_{\mathbf{x}} \quad & \|\mathbf{Ax} - \mathbf{b}\|_2^2, \\ \text{s.t.} \quad & \text{card}(\mathbf{x}) \leq c. \end{aligned}$$

- 秩：如果 $\mathcal{S}$ 是秩为 c 的矩阵的集合，那么 $\text{card}(\mathbf{V})$ 可以通过对 $\mathbf{V}$ 做奇异值分解， $\mathbf{V} = \sum_i \sigma_i \mathbf{u}_i \mathbf{u}_i^T$ ，然后保留前 c 大的奇异值及奇异向量，即 $\Pi_{\mathcal{S}}(\mathbf{V}) = \sum_{i=1}^c \sigma_i \mathbf{u}_i \mathbf{u}_i^T$ 。
- 布尔约束：如果 $\mathcal{S} = \{\mathbf{x} | x_i \in \{0, 1\}\}$ ，那么 $\Pi_{\mathcal{S}}(\mathbf{v})$ 就是简单地把每个元素变为 0 和 1 中离它更近的数。

非负矩阵分解和补全

非负矩阵分解和补全问题可以写成如下形式：

$$\begin{aligned} \min_{\mathbf{X}, \mathbf{Y}} \quad & \|\mathcal{P}_{\Omega}(\mathbf{XY} - \mathbf{M})\|_F^2, \\ \text{s.t.} \quad & \mathbf{X}_{ij} \geq 0, \mathbf{Y}_{ij} \geq 0, \forall i, j, \end{aligned}$$

其中， Ω 表示矩阵 $\mathbf{M}$ 中的已知元素的下标集合， $\mathcal{P}_{\Omega}(\mathbf{A})$ 表示得到一个新的矩阵 $\mathbf{A}'$ ，其下标在集合 Ω 中的所对应的元素等于矩阵 $\mathbf{A}$ 的对应元素，其下标不在集合 Ω 中的所对应的元素为0。注意到，这个问题是非凸的。

为了利用交替方向乘子法的优势，我们考虑如下的等价形式：

$$\begin{aligned} \min_{\mathbf{U}, \mathbf{V}, \mathbf{X}, \mathbf{Y}, \mathbf{Z}} \quad & \frac{1}{2} \|\mathbf{XY} - \mathbf{Z}\|_F^2, \\ \text{s.t.} \quad & \mathbf{X} = \mathbf{U}, \mathbf{Y} = \mathbf{V}, \\ & \mathbf{U} \geq 0, \mathbf{V} \geq 0, \\ & \mathcal{P}_{\Omega}(\mathbf{Z} - \mathbf{M}) = 0. \end{aligned}$$

非负矩阵分解和补全

$$L_{\alpha,\beta}(\mathbf{X}, \mathbf{Y}, \mathbf{Z}, \mathbf{U}, \mathbf{V}, \mathbf{\Lambda}, \mathbf{\Pi}) = \frac{1}{2} \|\mathbf{X}\mathbf{Y} - \mathbf{Z}\|_F^2 + \mathbf{\Lambda} \bullet (\mathbf{X} - \mathbf{U}) \\ + \mathbf{\Pi} \bullet (\mathbf{Y} - \mathbf{V}) + \frac{\alpha}{2} \|\mathbf{X} - \mathbf{U}\|_F^2 + \frac{\beta}{2} \|\mathbf{Y} - \mathbf{V}\|_F^2,$$

$$\mathbf{X}^{k+1} = \underset{\mathbf{X}}{\operatorname{argmin}} L_{\alpha,\beta}(\mathbf{X}, \mathbf{Y}^k, \mathbf{Z}^k, \mathbf{U}^k, \mathbf{V}^k, \mathbf{\Lambda}^k, \mathbf{\Pi}^k),$$

$$\mathbf{Y}^{k+1} = \underset{\mathbf{Y}}{\operatorname{argmin}} L_{\alpha,\beta}(\mathbf{X}^{k+1}, \mathbf{Y}, \mathbf{Z}^k, \mathbf{U}^k, \mathbf{V}^k, \mathbf{\Lambda}^k, \mathbf{\Pi}^k),$$

$$\mathbf{Z}^{k+1} = \underset{\mathcal{P}_{\Omega}(\mathbf{Z}-\mathbf{M})=0}{\operatorname{argmin}} L_{\alpha,\beta}(\mathbf{X}^{k+1}, \mathbf{Y}^{k+1}, \mathbf{Z}, \mathbf{U}^k, \mathbf{V}^k, \mathbf{\Lambda}^k, \mathbf{\Pi}^k),$$

$$\mathbf{U}^{k+1} = \underset{\mathbf{U} \geq 0}{\operatorname{argmin}} L_{\alpha,\beta}(\mathbf{X}^{k+1}, \mathbf{Y}^{k+1}, \mathbf{Z}^{k+1}, \mathbf{U}, \mathbf{V}^k, \mathbf{\Lambda}^k, \mathbf{\Pi}^k),$$

$$\mathbf{V}^{k+1} = \underset{\mathbf{V} \geq 0}{\operatorname{argmin}} L_{\alpha,\beta}(\mathbf{X}^{k+1}, \mathbf{Y}^{k+1}, \mathbf{Z}^{k+1}, \mathbf{U}^{k+1}, \mathbf{V}, \mathbf{\Lambda}^k, \mathbf{\Pi}^k),$$

$$\mathbf{\Lambda}^{k+1} = \mathbf{\Lambda}^k + \tau\alpha(\mathbf{X}^{k+1} - \mathbf{U}^{k+1}),$$

$$\mathbf{\Pi}^{k+1} = \mathbf{\Pi}^k + \tau\beta(\mathbf{Y}^{k+1} - \mathbf{V}^{k+1}).$$