

梯度类算法

文再文

北京大学北京国际数学研究中心

教材《最优化：建模、算法与理论》配套电子教案

<http://bicmr.pku.edu.cn/~wenzw/optbook.html>

- 1 梯度下降法
- 2 次梯度法
- 3 近似点梯度法
- 4 Nesterov加速算法

梯度下降法: $\min_x f(x)$

- 注意到 $\phi(\alpha) = f(x^k + \alpha d^k)$ 有泰勒展开

$$\phi(\alpha) = f(x^k) + \alpha \nabla f(x^k)^\top d^k + \mathcal{O}(\alpha^2 \|d^k\|^2).$$

- 由柯西不等式, 当 α 足够小时取 $d^k = -\nabla f(x^k)$ 会使函数下降最快.
- 因此梯度法就是选取 $d^k = -\nabla f(x^k)$ 的算法, 它的迭代格式为

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k).$$

步长 α_k 的选取可依赖于线搜索算法, 也可直接选取固定的 α_k .

- 另一种理解方式:

$$\begin{aligned} x^{k+1} &= \arg \min_x f(x^k) + \nabla f(x^k)^\top (x - x^k) + \frac{1}{\alpha_k} \|x - x^k\|_2^2 \\ &= \arg \min_x \|x - (x^k - \alpha_k \nabla f(x^k))\|_2^2 \\ &= x^k - \alpha_k \nabla f(x^k) \end{aligned}$$

梯度利普希茨连续

定义 (梯度利普希茨连续)

给定可微函数 f ，若存在 $L > 0$ ，对任意的 $x, y \in \text{dom}f$ 有

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad (1)$$

则称 f 是梯度利普希茨连续的，相应利普希茨常数为 L 。有时也简记为梯度 L -利普希茨连续或 L -光滑。

引理 (二次上界)

设可微函数 $f(x)$ 的定义域 $\text{dom}f = \mathbb{R}^n$ ，且为梯度 L -利普希茨连续的，则函数 $f(x)$ 有二次上界：

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2, \quad \forall x, y \in \text{dom}f. \quad (2)$$

可以证明:

$$\begin{aligned} & f(y) - f(x) - \nabla f(x)^T(y - x) \\ &= \int_0^1 (\nabla f(x + t(y - x)) - \nabla f(x))^T(y - x) dt \\ &\leq \int_0^1 \|\nabla f(x + t(y - x)) - \nabla f(x)\| \|y - x\| dt \\ &\leq \int_0^1 L \|y - x\|^2 t dt = \frac{L}{2} \|y - x\|^2, \end{aligned}$$

其中最后一行的不等式利用了梯度利普希茨连续的条件(1). 整理可得(2) 式成立.

梯度法在凸函数上的收敛性

考虑梯度法

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k)$$

假设：

- 设函数 $f(x)$ 为凸的梯度 L -利普希茨连续函数
- 极小值 $f^* = f(x^*) = \inf_x f(x)$ 存在且可达.
- 如果步长 α_k 取为常数 α 且满足 $0 < \alpha < \frac{1}{L}$

结论：点列 $\{x^k\}$ 的函数值收敛到最优值，且在函数值的意义下收敛速度为 $\mathcal{O}\left(\frac{1}{k}\right)$.

如果函数 f 还是 m -强凸函数，则梯度法的收敛速度会进一步提升为Q-线性收敛.

- 因为函数 f 是利普希茨可微函数, 对任意的 x , 根据二次上界引理,

$$f(x - \alpha \nabla f(x)) \leq f(x) - \alpha \left(1 - \frac{L\alpha}{2}\right) \|\nabla f(x)\|^2.$$

- 记 $\tilde{x} = x - \alpha \nabla f(x)$ 并限制 $0 < \alpha < \frac{1}{L}$, 我们有

$$\begin{aligned} f(\tilde{x}) &\leq f(x) - \frac{\alpha}{2} \|\nabla f(x)\|^2 \\ &\leq f^* + \nabla f(x)^T (x - x^*) - \frac{\alpha}{2} \|\nabla f(x)\|^2 \\ &= f^* + \frac{1}{2\alpha} (\|x - x^*\|^2 - \|x - x^* - \alpha \nabla f(x)\|^2) \\ &= f^* + \frac{1}{2\alpha} (\|x - x^*\|^2 - \|\tilde{x} - x^*\|^2), \end{aligned}$$

其中第一个不等式是因为 $0 < \alpha < \frac{1}{L}$, 第二个不等式为 f 的凸性.

- 在上式中取 $x = x^{i-1}, \tilde{x} = x^i$ 并将不等式对 $i = 1, 2, \dots, k$ 求和得到

$$\begin{aligned}\sum_{i=1}^k (f(x^i) - f^*) &\leq \frac{1}{2\alpha} \sum_{i=1}^k (\|x^{i-1} - x^*\|^2 - \|x^i - x^*\|^2) \\ &= \frac{1}{2\alpha} (\|x^0 - x^*\|^2 - \|x^k - x^*\|^2) \\ &\leq \frac{1}{2\alpha} \|x^0 - x^*\|^2.\end{aligned}$$

- 由于 $f(x^i)$ 是非增的, 所以

$$f(x^k) - f^* \leq \frac{1}{k} \sum_{i=1}^k (f(x^i) - f^*) \leq \frac{1}{2k\alpha} \|x^0 - x^*\|^2.$$

梯度法在强凸函数上的收敛性

定理 (梯度法在强凸函数上的收敛性)

设函数 $f(x)$ 为 m -强凸的梯度 L -利普希茨连续函数, $f(x^*) = \inf_x f(x)$ 存在且可达. 如果步长 α 满足 $0 < \alpha < \frac{2}{m+L}$, 那么由梯度下降法迭代得到的点列 $\{x^k\}$ 收敛到 x^* , 且为 Q -线性收敛.

- 首先根据 f 强凸且 ∇f 利普希茨连续, 可得

$$g(x) = f(x) - \frac{m}{2}x^T x$$

为凸函数且 $\frac{L-m}{2}x^T x - g(x)$ 为凸函数.

- 由引理知函数 $g(x)$ 是梯度 $(L-m)$ -利普希茨连续的. 再次利用引理可得关于 $g(x)$ 的余强制性

$$(\nabla g(x) - \nabla g(y))^T(x - y) \geq \frac{1}{L-m} \|\nabla g(x) - \nabla g(y)\|^2.$$

梯度法在强凸函数上的收敛性

- 代入 $g(x)$ 的表达式, 可得

$$(\nabla f(x) - \nabla f(y))^T(x - y) \geq \frac{mL}{m+L}\|x - y\|^2 + \frac{1}{m+L}\|\nabla f(x) - \nabla f(y)\|^2.$$

- 再估计固定步长下梯度法的收敛速度. 设步长 $\alpha \in \left(0, \frac{2}{m+L}\right)$, 对 x^k, x^* 应用上式并注意到 $\nabla f(x^*) = 0$ 得

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \alpha \nabla f(x^k) - x^*\|^2 \\&= \|x^k - x^*\|^2 - 2\alpha \nabla f(x^k)^T(x^k - x^*) + \alpha^2 \|\nabla f(x^k)\|^2 \\&\leq \left(1 - \alpha \frac{2mL}{m+L}\right) \|x^k - x^*\|^2 + \alpha \left(\alpha - \frac{2}{m+L}\right) \|\nabla f(x^k)\|^2 \\&\leq \left(1 - \alpha \frac{2mL}{m+L}\right) \|x^k - x^*\|^2\end{aligned}$$

$$\Rightarrow \|x^k - x^*\|^2 \leq c^k \|x^0 - x^*\|^2, \quad c = 1 - \alpha \frac{2mL}{m+L} < 1.$$

函数值收敛

强凸函数假设下

- 迭代点列 $\{x^k\}$ Q-线性收敛
- 如果取 $t = \frac{2}{m+L}$, 则有 $c = \frac{(\gamma-1)^2}{(\gamma+1)}$ 且 $\gamma = L/m$

如果 $\text{dom } f = \mathbf{R}^n$ 且 f 有极小点 x^* , 则

$$\frac{1}{2L} \|\nabla f(x)\|_2^2 \leq f(x) - f(x^*) \leq \frac{L}{2} \|x - x^*\|_2^2 \quad \forall x$$

因此:

$$f(x^k) - f^* \leq \frac{L}{2} \|x^k - x^*\|_2^2 \leq \frac{c^k L}{2} \|x^0 - x^*\|_2^2$$

函数值的估计: 达到 $f(x^k) - f^* \leq \epsilon$ 的迭代步数是 $O(\log(1/\epsilon))$

提纲

- 1 梯度下降法
- 2 次梯度法
- 3 近似点梯度法
- 4 Nesterov加速算法

次梯度

- 可微凸函数 f 的一阶条件:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x)$$

- 设 f 为适当凸函数, $x \in \mathbf{dom} f$. 若向量 $g \in \mathbb{R}^n$ 满足

$$f(y) \geq f(x) + g^T(y - x), \quad \forall y \in \mathbf{dom} f,$$


则称 g 为函数 f 在点 x 处的一个次梯度.

- 进一步地, 称集合

$$\partial f(x) = \{g \mid g \in \mathbb{R}^n, f(y) \geq f(x) + g^T(y - x), \forall y \in \mathbf{dom} f\}$$

为 f 在点 x 处的次微分.



$f(x) = \max\{f_1(x), f_2(x)\}$ f_1, f_2 是可微凸函数



- 点 x_0 处的次梯度可取范围 $[\nabla f_1(x_0), \nabla f_2(x_0)]$
- 如果 $f_1(\hat{x}) > f_2(\hat{x})$, f 在点 $\hat{x}$ 处的次梯度等于 $\nabla f_1(\hat{x})$
- 如果 $f_1(\hat{x}) < f_2(\hat{x})$, f 在点 $\hat{x}$ 处的次梯度等于 $\nabla f_2(\hat{x})$

例

- 绝对值函数 $f(x) = |x|$



- 欧几里得范数 $f(x) = \|x\|_2$

如果 $x \neq 0$, $\partial f(x) = \frac{1}{\|x\|_2}x$, 如果 $x = 0$, $\partial f(x) = \{g \mid \|g\|_2 \leq 1\}$

次梯度算法结构

为了极小化一个不可微的凸函数 f ，可类似梯度法构造如下次梯度算法的迭代格式：

$$x^{k+1} = x^k - \alpha_k g^k, \quad g^k \in \partial f(x^k),$$

其中 $\alpha_k > 0$ 为步长。它通常有如下四种选择：

- 1 固定步长 $\alpha_k = \alpha$ ；
- 2 固定 $\|x^{k+1} - x^k\|$ ，即 $\alpha_k \|g^k\|$ 为常数；
- 3 消失步长 $\alpha_k \rightarrow 0$ 且 $\sum_{k=0}^{\infty} \alpha_k = +\infty$ ；
- 4 选取 α_k 使其满足某种线搜索准则。

下面我们讨论在不同步长取法下次梯度算法的收敛性质。

假设条件

- (1) f 为凸函数；
- (2) f 至少存在一个有限的极小值点 x^* ，且 $f(x^*) > -\infty$ ；
- (3) f 为利普希茨连续的，即

$$|f(x) - f(y)| \leq G\|x - y\|, \quad \forall x, y \in \mathbb{R}^n,$$

其中 $G > 0$ 为利普希茨常数.

我们下面证明这等价于 $f(x)$ 的次梯度是有界的，即

$$\|g\| \leq G, \quad \forall g \in \partial f(x), x \in \mathbb{R}^n.$$

证明：

- 充分性：假设 $\|g\|_2 \leq G, \forall g \in \partial f(x)$ ；取 $g_y \in \partial f(y), g_x \in \partial f(x)$ ：

$$g_x^T(x - y) \geq f(x) - f(y) \geq g_y^T(x - y)$$

再由柯西不等式

$$G\|x - y\|_2 \geq f(x) - f(y) \geq -G\|x - y\|_2$$

- 必要性：反设存在 x 和 $g \in \partial f(x)$ ，使得 $\|g\|_2 > G$ ；取 $y = x + \frac{g}{\|g\|_2}$

$$\begin{aligned} f(y) &\geq f(x) + g^T(y - x) \\ &= f(x) + \|g\|_2 \\ &> f(x) + G \end{aligned}$$

这与 $f(x)$ 是 G -利普希茨连续的矛盾。

收敛性分析

- 次梯度方法不是一个下降方法，即无法保证 $f(x^{k+1}) < f(x^k)$ ；
- 收敛性分析的关键是分析 $f(x)$ 历史迭代的最优点所满足的性质。
- 设 x^* 是 $f(x)$ 的一个全局极小值点， $f^* = f(x^*)$ ，根据迭代格式，

$$\begin{aligned}\|x^{i+1} - x^*\|^2 &= \|x^i - \alpha_i g^i - x^*\|^2 \\ &= \|x^i - x^*\|^2 - 2\alpha_i \langle g^i, x^i - x^* \rangle + \alpha_i^2 \|g^i\|^2 \\ &\leq \|x^i - x^*\|^2 - 2\alpha_i (f(x^i) - f^*) + \alpha_i^2 G^2\end{aligned}$$

- 结合 $i = 0, \dots, k$ 时相应的不等式，并定义 $\hat{f}^k = \min_{0 \leq i \leq k} f(x^i)$ ：

$$\begin{aligned}2 \left(\sum_{i=0}^k \alpha_i \right) (\hat{f}^k - f^*) &\leq \|x^0 - x^*\|^2 - \|x^{k+1} - x^*\|^2 + G^2 \sum_{i=0}^k \alpha_i^2 \\ &\leq \|x^0 - x^*\|^2 + G^2 \sum_{i=0}^k \alpha_i^2\end{aligned}$$

不同步长下的收敛性

(1) 取 $\alpha_i = t$ 为固定步长, 则

$$\hat{f}^k - f^* \leq \frac{\|x^0 - x^*\|^2}{2kt} + \frac{G^2 t}{2};$$

- $\hat{f}^k$ 无法保证收敛性
- 当 k 足够大时, $\hat{f}^k$ 近似为 $G^2 t/2$ -次优的

(2) 取 α_i 使得 $\|x^{i+1} - x^i\|$ 固定, 即 $\alpha_i \|g^i\| = s$ 为常数, 则

$$\hat{f}^k - f^* \leq \frac{G\|x^0 - x^*\|^2}{2ks} + \frac{Gs}{2};$$

- $\hat{f}^k$ 无法保证收敛性
- 当 k 足够大时, $\hat{f}^k$ 近似为 $Gs/2$ -次优的

不同步长下的收敛性

(3) 取 α_i 为消失步长, 即 $\alpha_i \rightarrow 0$ 且 $\sum_{i=0}^{\infty} \alpha_i = +\infty$, 则

$$\hat{f}^k - f^* \leq \frac{\|x^0 - x^*\|^2 + G^2 \sum_{i=0}^k \alpha_i^2}{2 \sum_{i=0}^k \alpha_i};$$

进一步可得 $\hat{f}^k$ 收敛到 f^* .

- 和梯度法不同, 只有当 α_k 取消失步长时 $\hat{f}^k$ 才具有收敛性.
- 一个常用的步长取法是 $\alpha_k = \frac{1}{k}$.

固定迭代步数下的最优步长

- 假设 $\|x^0 - x^*\| \leq R$, 并且总迭代步数 k 是给定的, 在固定步长下,

$$\hat{f}^k - f^* \leq \frac{\|x^0 - x^*\|^2}{2kt} + \frac{G^2 t}{2} \leq \frac{R^2}{2kt} + \frac{G^2 t}{2}.$$

- 由平均值不等式知当 t 满足 $\frac{R^2}{2kt} = \frac{G^2 t}{2}$, 即 $t = \frac{R}{G\sqrt{k}}$ 时, 右端达到最小.
- k 步后得到的上界是

$$\hat{f}^k - f^* \leq \frac{GR}{\sqrt{k}}$$

- 这表明在 $k = O(1/\epsilon^2)$ 步迭代后可以得到 $\hat{f}^k - f^* \leq \epsilon$ 的精度
- 类似地可证明第二类步长选取策略下, 取 $s = \frac{R}{\sqrt{k}}$, 可得到估计

$$\hat{f}^k - f^* \leq \frac{GR}{\sqrt{k}}.$$

提纲

- 1 梯度下降法
- 2 次梯度法
- 3 近似点梯度法
- 4 Nesterov加速算法

复合优化问题

我们将考虑如下复合优化问题：

$$\min_{x \in \mathbb{R}^n} \quad \psi(x) = f(x) + h(x)$$

- 函数 f 为可微函数，其定义域 $\text{dom } f = \mathbb{R}^n$
- 函数 h 为凸函数，可以是非光滑的，并且邻近算子容易计算
- LASSO问题： $f(x) = \frac{1}{2} \|Ax - b\|^2$ ， $h(x) = \mu \|x\|_1$
- 次梯度法计算的复杂度： $\mathcal{O}(1/\sqrt{k})$

是否可以设计复杂度为 $\mathcal{O}(1/k)$ 的算法？

邻近算子

定义邻近算子：

$$\text{prox}_h(x) = \underset{u}{\operatorname{argmin}} \left(h(u) + \frac{1}{2} \|u - x\|_2^2 \right)$$

直观理解：求解一个距 x 不算太远的点 u ，并使函数值 $h(u)$ 也相对较小

定理（邻近算子是良定义的）

如果 h 为闭凸函数，则对任意 x ， $\text{prox}_h(x)$ 存在且唯一

Proof.

首先注意到 $h(u) + \frac{1}{2} \|u - x\|_2^2$ 是强凸函数，则

- 存在性：强凸函数的所有 α -下水平集有界，故由Weierstrass定理知最小值存在
- 唯一性：强凸函数最小值唯一

邻近算子与次梯度的关系

定理

若 h 是适当的闭凸函数, 则 $u = \text{prox}_h(x) \iff x - u \in \partial h(u)$

Proof.

若 $u = \text{prox}_h(x)$, 则由最优性条件得 $0 \in \partial h(u) + (u - x)$, 因此有 $x - u \in \partial h(u)$. 反之, 若 $x - u \in \partial h(u)$ 则由次梯度的定义可得到

$$h(v) \geq h(u) + (x - u)^T(v - u), \quad \forall v \in \text{dom } h$$

两边同时加 $\frac{1}{2}\|v - x\|^2$, 即有

$$\begin{aligned} h(v) + \frac{1}{2}\|v - x\|^2 &\geq h(u) + (x - u)^T(v - u) + \frac{1}{2}\|(v - u) - (x - u)\|^2 \\ &\geq h(u) + \frac{1}{2}\|u - x\|^2, \quad \forall v \in \text{dom } h \end{aligned}$$

根据定义可得 $u = \text{prox}_h(x)$.

邻近算子的例子

在近似点梯度法中，我们关心那些邻近算子 prox_{th} 容易计算的函数 h

例： ℓ_1 范数

$$h(x) = \|x\|_1, \quad \text{prox}_{th}(x) = \text{sign}(x) \max\{|x| - t, 0\}$$

Proof.

邻近算子 $u = \text{prox}_{th}(x)$ 的最优性条件为

$$x - u \in t\partial\|u\|_1 = \begin{cases} \{t\}, & u > 0 \\ [-t, t], & u = 0 \\ \{-t\}, & u < 0 \end{cases}$$

当 $x > t$ 时, $u = x - t$; 当 $x < -t$ 时, $u = x + t$; 当 $x \in [-t, t]$ 时, $u = 0$, 即有 $u = \text{sign}(x) \max\{|x| - t, 0\}$.

邻近算子的例子

例： ℓ_2 范数

$$h(x) = \|x\|_2, \quad \text{prox}_{th}(x) = \begin{cases} \left(1 - \frac{t}{\|x\|_2}\right) x, & \|x\|_2 \geq t, \\ 0, & \text{其他}. \end{cases}$$

Proof.

邻近算子 $u = \text{prox}_{th}(x)$ 的最优性条件为

$$x - u \in t\partial\|u\|_2 = \begin{cases} \left\{ \frac{tu}{\|u\|_2} \right\}, & u \neq 0, \\ \{w : \|w\|_2 \leq t\}, & u = 0, \end{cases}$$

因此, 当 $\|x\|_2 > t$ 时, $u = x - \frac{tx}{\|x\|_2^2}$; 当 $\|x\|_2 \leq t$ 时, $u = 0$.

闭凸集上的投影

设 C 为闭凸集，则示性函数 I_C 的邻近算子为点 x 到 C 的投影 $\mathcal{P}_C(x)$ ：

$$\begin{aligned}\text{prox}_{I_C}(x) &= \arg \min_u \left\{ I_C(u) + \frac{1}{2} \|u - x\|^2 \right\} \\ &= \operatorname{argmin}_{u \in C} \|u - x\|^2 = \mathcal{P}_C(x)\end{aligned}$$

这个等式具有几何意义：

$$u = \mathcal{P}_C(x) \Leftrightarrow (x - u)^T (z - u) \leq 0, \quad \forall z \in C$$

近似点梯度法

对于光滑部分 f 做梯度下降，对于非光滑部分 h 使用邻近算子，则近似点梯度法的迭代格式为

$$x^{k+1} = \text{prox}_{t_k h} (x^k - t_k \nabla f(x^k)) \quad (3)$$

其中 $t_k > 0$ 为每次迭代的步长，它可以是一个常数或者由线搜索得出。

Algorithm 近似点梯度法

- 1: 输入：函数 $f(x)$, $h(x)$, 初始点 x^0 .
 - 2: **while** 未达到收敛准则 **do**
 - 3: $x^{k+1} = \text{prox}_{t_k h} (x^k - t_k \nabla f(x^k))$.
 - 4: **end while**
-

对近似点梯度法的理解

根据定义, (3)式等价于

$$\begin{aligned}x^{k+1} &= \arg \min_u \left\{ h(u) + \frac{1}{2t_k} \|u - x^k + t_k \nabla f(x^k)\|^2 \right\} \\&= \arg \min_u \left\{ h(u) + f(x^k) + \nabla f(x^k)^T (u - x^k) + \frac{1}{2t_k} \|u - x^k\|^2 \right\}\end{aligned}$$

根据邻近算子与次梯度的关系, 又可以形式地写成

$$x^{k+1} = x^k - t_k \nabla f(x^k) - t_k g^k, \quad g^k \in \partial h(x^{k+1}).$$

即对光滑部分做显式的梯度下降, 关于非光滑部分做隐式的梯度下降.

LASSO问题

考虑用近似点梯度法求解 LASSO 问题

$$\min_x \mu \|x\|_1 + \frac{1}{2} \|Ax - b\|^2.$$

令 $f(x) = \frac{1}{2} \|Ax - b\|^2$, $h(x) = \mu \|x\|_1$, 则

$$\begin{aligned}\nabla f(x) &= A^T(Ax - b), \\ \text{prox}_{th}(x) &= \text{sign}(x) \max \{|x| - t\mu, 0\}.\end{aligned}$$


故相应的迭代格式为：

$$\begin{aligned}y^k &= x^k - t_k A^T (Ax^k - b), \\ x^{k+1} &= \text{sign}(y^k) \max \{|y^k| - t_k \mu, 0\},\end{aligned}$$

即第一步做梯度下降，第二步做收缩

LASSO问题

我们还可以使用BB步长加速收敛



收敛性分析

基本假设：

- f 在 $\mathbb{R}^n$ 上是凸的; ∇f 为 L -利普希茨连续, 即

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y$$

- h 是适当的闭凸函数 (因此 prox_{th} 的定义是合理的);
- 函数 $\psi(x) = f(x) + h(x)$ 的最小值 ψ^* 是有限的, 并且在点 x^* 处可取到(并不要求唯一).

梯度映射

在基本假设的基础上，我们定义梯度映射：

$$G_t(x) = \frac{1}{t} (x - \text{prox}_{th}(x - t\nabla f(x))) \quad (t > 0) \quad (4)$$

不难推出梯度映射具有以下性质：

- “负搜索方向”： $x^{k+1} = \text{prox}_{th}(x^k - t\nabla f(x^k)) = x^k - tG_t(x^k)$
- 根据邻近算子和次梯度的关系，我们有

$$G_t(x) - \nabla f(x) \in \partial h(x - tG_t(x)) \quad (5)$$

- 与算法的收敛性的关系：

$$G_t(x) = 0 \iff x \text{ 为 } \psi(x) = f(x) + h(x) \text{ 的最小值点}$$

收敛性分析

$G_t(x) = 0 \iff x$ 为 $\psi(x) = f(x) + h(x)$ 的最小值点

证明：

$$\begin{aligned} 0 \in \nabla f(x) + \partial h(x) &\iff x - t\nabla f(x) \in x + t\partial h(x) \\ &\iff x - (x - t\nabla f(x)) \in t\partial h(x) \\ &\iff x = \text{prox}_{th}(x - t\nabla f(x)) \\ &\iff G_t(x) = 0. \end{aligned}$$

定理 1(固定步长近似点梯度法的收敛性)

取定步长为 $t_k = t \in (0, \frac{1}{L}]$, 设 $\{x^k\}$ 由迭代格式(3)产生, 则

$$\psi(x^k) - \psi^* \leq \frac{1}{2kt} \|x^0 - x^*\|^2$$

定理证明

证明 根据利普希茨连续“二次上界”的性质，得到

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2, \quad \forall x, y \in \mathbb{R}^n$$

令 $y = x - tG_t(x)$, 有

$$\begin{aligned} f(x - tG_t(x)) &\leq f(x) - t\nabla f(x)^T G_t(x) + \frac{t^2 L}{2} \|G_t(x)\|^2 \\ &\leq f(x) - t\nabla f(x)^T G_t(x) + \frac{t}{2} \|G_t(x)\|^2 \end{aligned} \quad (6)$$

此外，由 $f(x), h(x)$ 为凸函数，结合(4)式我们有

$$h(x - tG_t(x)) \leq h(z) - (G_t(x) - \nabla f(x))^T (z - x + tG_t(x)) \quad (7)$$

$$f(x) \leq f(z) - \nabla f(x)^T (z - x) \quad (8)$$

将(6)(7)(8)式相加可得对任意 $z \in \text{dom } \psi$ 有

$$\psi(x - tG_t(x)) \leq \psi(z) + G_t(x)^T(x - z) - \frac{t}{2} \|G_t(x)\|^2 \quad (9)$$

定理证明

由 $x^i = x^{i-1} - tG_t(x^{i-1})$, 在不等式(9) 中, 取 $z = x^*, x = x^{i-1}$ 得到

$$\begin{aligned}\psi(x^i) - \psi^* &\leq G_t(x^{i-1})^T (x^{i-1} - x^*) - \frac{t}{2} \|G_t(x^{i-1})\|^2 \\ &= \frac{1}{2t} \left(\|x^{i-1} - x^*\|^2 - \|x^{i-1} - x^* - tG_t(x^{i-1})\|^2 \right) \\ &= \frac{1}{2t} \left(\|x^{i-1} - x^*\|^2 - \|x^i - x^*\|^2 \right)\end{aligned}\quad (10)$$

取 $i = 1, 2, \dots, k$ 并累加, 得

$$\begin{aligned}\sum_{i=1}^k (\psi(x^i) - \psi^*) &\leq \frac{1}{2t} \sum_{i=1}^k \left(\|x^{i-1} - x^*\|^2 - \|x^i - x^*\|^2 \right) \\ &= \frac{1}{2t} \left(\|x^0 - x^*\|^2 - \|x^k - x^*\|^2 \right) \\ &\leq \frac{1}{2t} \|x^0 - x^*\|^2.\end{aligned}$$

定理证明

注意到在不等式(9)中, 取 $z = x^{i-1}$ 即得:

$$\psi(x^i) \leq \psi(x^{i-1}) - \frac{t}{2} \|G_t(x^{i-1})\|^2$$

即 $\psi(x^i)$ 不增, 因此

$$\psi(x^k) - \psi^* \leq \frac{1}{k} \sum_{i=1}^k (\psi(x^i) - \psi^*) \leq \frac{1}{2kt} \|x^0 - x^*\|^2$$

- 1 梯度下降法
- 2 次梯度法
- 3 近似点梯度法
- 4 Nesterov加速算法

典型问题形式

考虑如下复合优化问题：

$$\min_{x \in \mathbb{R}^n} \quad \psi(x) = f(x) + h(x) \quad (11)$$

- $f(x)$ 是连续可微的凸函数，且梯度是利普西茨连续的：

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|;$$

- $h(x)$ 是适当的闭凸函数，且邻近算子容易计算：

$$\text{prox}_h(x) = \operatorname{argmin}_{u \in \operatorname{dom} h} \left\{ h(u) + \frac{1}{2} \|x - u\|^2 \right\}$$

- 对于上述问题，近似点梯度法

$$x^{k+1} = \text{prox}_{t_k h}(x^k - t_k \nabla f(x^k))$$

在步长取常数 $t_k = 1/L$ 时，收敛速度为 $\mathcal{O}(1/k)$.

Nesterov加速算法简史

- 如果仅用梯度信息，我们能不能取得更快的收敛速度？
- Nesterov分别在1983年、1988年和2005年提出了三种改进的一阶算法，收敛速度能达到 $\mathcal{O}\left(\frac{1}{k^2}\right)$ 。实际上，这三种算法都可以应用到近似点梯度算法上。
- 在Nesterov加速算法刚提出的时候，由于牛顿算法有更快的收敛速度，Nesterov加速算法在当时并没有引起太多的关注。但近年来，随着数据量的增大，牛顿型方法由于其过大的计算复杂度，不便于有效地应用到实际中，Nesterov加速算法作为一种快速的一阶算法重新被挖掘出来并迅速流行起来。
- Beck和Teboulle就在2008年给出了Nesterov在1983年提出的算法的近似点梯度法版本——FISTA。

- FISTA算法由两步组成：第一步沿着前两步的计算方向计算一个新点，第二步在该新点处做一步近似点梯度迭代（如图所示）。




Figure: FISTA算法图示

- FISTA算法：

$$y^k = x^{k-1} + \frac{k-2}{k+1}(x^{k-1} - x^{k-2})$$

$$x^k = \text{prox}_{t_k h}(y^k - t_k \nabla f(y^k))$$
(12)

FISTA的等价形式

- FISTA的一个等价变形：

$$\begin{aligned}y^k &= (1 - \gamma_k)x^{k-1} + \gamma_k v^{k-1} \\x^k &= \text{prox}_{t_k h}(y^k - t_k \nabla f(y^k)) \\v^k &= x^{k-1} + \frac{1}{\gamma_k}(x^k - x^{k-1})\end{aligned}\tag{13}$$

- 当 $\gamma_k = \frac{2}{k+1}$ 时，并且取固定步长时，两个版本是等价的；
- 但是当 γ_k 采用别的取法时，(13)将给出另一个版本的加速算法。
- 也就是说，(12)中 $\frac{k-2}{k+1}$ 可以取其他值。

FISTA的收敛条件

下面给出算法(13)以 $\mathcal{O}\left(\frac{1}{k^2}\right)$ 的速度收敛的条件：

$$f(x^k) \leq f(y^k) + \langle \nabla f(y^k), x^k - y^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|_2^2, \quad (14)$$

$$\gamma_1 = 1, \quad \frac{(1 - \gamma_i)t_i}{\gamma_i^2} \leq \frac{t_{i-1}}{\gamma_{i-1}^2}, \quad i > 1, \quad (15)$$

$$\frac{\gamma_k^2}{t_k} = \mathcal{O}\left(\frac{1}{k^2}\right). \quad (16)$$

- 可以看到当取 $t_k = \frac{1}{L}$, $\gamma_k = \frac{2}{k+1}$ 时, 以上条件满足.
- γ_k 的选取并不唯一, 例如我们可以采取

$$\gamma_1 = 1, \quad \frac{1}{\gamma_k} = \frac{1}{2} \left(1 + \sqrt{1 + \frac{4}{\gamma_{k-1}}} \right).$$

第二类Nesterov加速算法

- 对于复合优化问题(11)，我们给出第二类Nesterov加速算法：

$$\begin{aligned} z^k &= (1 - \gamma_k)x^{k-1} + \gamma_k y^{k-1} \\ y^k &= \text{prox}_{(t_k/\gamma_k)h} \left(y^{k-1} - \frac{t_k}{\gamma_k} \nabla f(z^k) \right) \\ x^k &= (1 - \gamma_k)x^{k-1} + \gamma_k y^k \end{aligned} \quad (17)$$

- 和经典FISTA 算法的一个重要区别在于，第二类Nesterov 加速算法中的三个序列 $\{x^k\}$ ， $\{y^k\}$ 和 $\{z^k\}$ 都可以保证在定义域内。而FISTA 算法中的序列 $\{y^k\}$ 不一定在定义域内。

第二类Nesterov加速算法

- 第二类Nesterov 加速算法的一步迭代可参考下图。

$$y^k = \text{prox}_{(t_k/\gamma_k)h}(y^{k-1} - (t_k/\gamma_k)\nabla f(z^k))$$




Figure: 第二类Nesterov加速算法的一步迭代

收敛性假设

- f 在其定义域 $\text{dom } f = \mathbb{R}^n$ 内为凸的, ∇f 在常数 L 意义下利普西茨连续, 即

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y;$$

- h 是适当的闭凸函数;
- $\psi(x)$ 的最小值 ψ^* 是有限的, 并且在点 x^* 处可以取到.

定理 (固定步长FISTA算法收敛速度)

在上述收敛性假设的条件下, 当用(13)求解凸复合优化问题(11)时, 若取固定步长 $t_k = \frac{1}{L}$, 则

$$\psi(x^k) - \psi(x^*) \leq \frac{2L}{(k+1)^2} \|x^0 - x^*\|^2. \quad (18)$$

定理证明

- 根据 $x^k = \text{prox}_{t_k h}(y^k - t_k \nabla f(y^k))$, 可知

$$-x^k + y^k - t_k \nabla f(y^k) \in t_k \partial h(x^k).$$

故对于任意的 x , 有

$$t_k h(x) \geq t_k h(x^k) + \langle -x^k + y^k - t_k \nabla f(y^k), x - x^k \rangle. \quad (19)$$

- 由 f 的凸性、梯度利普希茨连续和 $t_k = \frac{1}{L}$ 可以得到

$$f(x^k) \leq f(y^k) + \langle \nabla f(y^k), x^k - y^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|^2. \quad (20)$$

- 结合以上两个不等式，对于任意的 x 有

$$\begin{aligned}
 \psi(x^k) &= f(x^k) + h(x^k) \\
 &\leq h(x) + f(y^k) + \langle \nabla f(y^k), x - y^k \rangle + \frac{1}{t_k} \langle x^k - y^k, x - x^k \rangle \\
 &\quad + \frac{1}{2t_k} \|x^k - y^k\|^2 \\
 &\leq h(x) + f(x) + \frac{1}{t_k} \langle x^k - y^k, x - x^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|^2 \\
 &= \psi(x) + \frac{1}{t_k} \langle x^k - y^k, x - x^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|^2.
 \end{aligned} \tag{21}$$

- 在(21)式中分别取 $x = x^{k-1}$ 和 $x = x^*$ ，并记 $\psi(x^*) = \psi^*$ ，再分别乘 $1 - \gamma_k$ 和 γ_k 并相加得到

$$\begin{aligned}
 &\psi(x^k) - \psi^* - (1 - \gamma_k)(\psi(x^{k-1}) - \psi^*) \\
 &\leq \frac{1}{t_k} \langle x^k - y^k, (1 - \gamma_k)x^{k-1} + \gamma_k x^* - x^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|^2.
 \end{aligned} \tag{22}$$

- 结合迭代式

$$\begin{aligned}v^k &= x^{k-1} + \frac{1}{\gamma_k}(x^k - x^{k-1}), \\y^k &= (1 - \gamma_k)x^{k-1} + \gamma_k v^{k-1},\end{aligned}$$

不等式(22)可以化为

$$\begin{aligned}& \psi(x^k) - \psi^* - (1 - \gamma_k)(\psi(x^{k-1}) - \psi^*) \\& \leq \frac{1}{2t_k}(\|y^k - (1 - \gamma_k)x^{k-1} - \gamma_k x^*\|^2 - \|x^k - (1 - \gamma_k)x^{k-1} - \gamma_k x^*\|^2) \\& = \frac{\gamma_k^2}{2t_k}(\|v^{k-1} - x^*\|^2 - \|v^k - x^*\|^2).\end{aligned}\tag{23}$$

- t_k, γ_k 的取法满足不等式

$$\frac{1 - \gamma_k}{\gamma_k^2} t_k \leq \frac{1}{\gamma_{k-1}^2} t_{k-1}, \quad (24)$$

可以得到一个有关相邻两步迭代的不等式

$$\frac{t_k}{\gamma_k^2} (\psi(x^k) - \psi^*) + \frac{1}{2} \|v^k - x^*\|^2 \leq \frac{t_{k-1}}{\gamma_{k-1}^2} (\psi(x^{k-1}) - \psi^*) + \frac{1}{2} \|v^{k-1} - x^*\|^2. \quad (25)$$

- 反复利用(25)式，我们有

$$\frac{t_k}{\gamma_k^2} (\psi(x^k) - \psi^*) + \frac{1}{2} \|v^k - x^*\|^2 \leq \frac{t_1}{\gamma_1^2} (\psi(x^1) - \psi^*) + \frac{1}{2} \|v^1 - x^*\|^2. \quad (26)$$

- 对 $k = 1$, 注意到 $\gamma_1 = 1, v^0 = x^0$, 再次利用(23)式可得

$$\begin{aligned} & \frac{t_1}{\gamma_1^2}(\psi(x^1) - \psi^*) + \frac{1}{2}\|v^1 - x^*\|^2 \\ & \leq \frac{(1 - \gamma_1)t_1}{\gamma_1^2}(\psi(x^0) - \psi^*) + \frac{1}{2}\|v^0 - x^*\|^2 = \frac{1}{2}\|x^0 - x^*\|^2. \end{aligned} \tag{27}$$

- 结合(26)式和(27)式可以得到(18)式.

证明思路

- 证明中关键的一步在于建立(25)式，而建立这个递归关系并不需要 $t = 1/L$, $\gamma_k = 2/(k+1)$ 这一具体条件，我们只需要保证条件(14)和条件(15)成立即可。
- 条件(14)主要依赖于 $f(x)$ 的梯度利普希茨连续性；而(15)的成立依赖于 γ_k 和 t_k 的选取。
- 条件(16)的成立保证了(13)的收敛速度达到 $\mathcal{O}(\frac{1}{k^2})$ 。
- 如果抽取条件(14)-(16)作为算法收敛的一般条件，则可以证明一大类FISTA算法的变形都具有 $\mathcal{O}(\frac{1}{k^2})$ 的收敛速度。